1 离散概率 Discrete Probability

1.1 条件概率 Conditional Probability

定义：$\Pr[A \mid B] = \frac{\Pr[A \cap B]}{\Pr[B]}$.
独立：$\Pr[A \cap B] = \Pr[A]\Pr[B]$. 当 $\Pr[B] \neq 0$ 时等价于 $\Pr[A \mid B] = \Pr[A]$.
互相独立：对于所有 $I \subseteq [m]$ 均有 $\Pr[\bigcap_{i \in I} A_i] = \prod_{i \in I} \Pr[A_i]$.
互相独立不等于两两独立：抛硬币第一次向上、第二次向上、恰一次向上。
链式法则：$\Pr[\bigcap_{i=1}^{m} A_i] = \prod_{i=1}^{m} \Pr[A_i \mid \bigcap_{j=1}^{i-1} A_j]$.
全概率公式：$\Pr[A] = \sum_{i=1}^{m} \Pr[A \mid B_i]\Pr[B_i]$，其中 B_i 两两互斥且并集为全集。

1.2 条件期望 Conditional Expectation

定义：$\mathbb{E}[X \mid B] = \frac{\mathbb{E}[X \cdot \mathbb{1}_B]}{\Pr[B]}$.
定义：$\mathbb{E}[X \mid Y] : \Omega \to \mathbb{R}, \omega \mapsto \mathbb{E}[X \mid Y = Y(\omega)]$.
全期望公式：$\mathbb{E}[X] = \sum_{i=1}^{m} \mathbb{E}[X \mid B_i]\Pr[B_i]$，其中 B_i 两两互斥且并集为全集。
全期望公式：$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X \mid Y]]$。
塔式性质：$\mathbb{E}[\mathbb{E}[X \mid f(Y)] \mid Y] = \mathbb{E}[\mathbb{E}[X \mid Y] \mid f(Y)] = \mathbb{E}[X \mid f(Y)]$.
独立：对于所有集合 A, B 均有 $\Pr[X \in A, Y \in B] = \Pr[X \in A]\Pr[Y \in B]$.
互相独立：对于所有 A_i 均有 $\Pr[\bigcap_i \{X_i \in A_i\}] = \prod_i \Pr[X_i \in A_i]$.
独立性质：$\mathbb{E}[\prod_{i=1}^{n} X_i] = \prod_{i=1}^{n} \mathbb{E}[X_i]$.

2 集中不等式 Sampling and Concentration

2.1 马尔可夫不等式 Markov' s Inequality

对于非负随机变量 X 与任意 $a > 0$ 有 $\Pr[X \geq a] \leq \frac{\mathbb{E}[X]}{a}$。即 $\Pr[X \geq \alpha\mathbb{E}[X]] \leq \frac{1}{\alpha}$.
变形：$\Pr[f(X) \geq a] \leq \frac{\mathbb{E}[f(X)]}{a}$.
变形：$\Pr[X \leq a] \leq \frac{u - \mathbb{E}[X]}{u - a}$ 对于 $\Pr[X \leq u] = 1$.

2.2 琴生不等式 Jensen' s Inequality

凸函数：$f(tx+(1-t)y) \leq tf(x)+(1-t)f(y)$. 对于任意 y 均存在 α 使得 $f(x) \geq f(y)+\alpha(x-y)$.
代入 $y = \mathbb{E}[X]$ 可得到 $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$. 定义 L^p 范数为 $\|X\|_p := \mathbb{E}\left[|X|^p\right]^{1/p}$.
Lyapunov' s inequality: $\|X\|_p \leq \|X\|_q \quad \text{if } p \leq q$.
Hölder' s inequality: $\|XY\|_1 \leq \|X\|_p \|Y\|_q \quad \text{if } 1/p + 1/q = 1$.
Young' s inequality: $\|XY\|_1 \leq \frac{1}{p}\|X\|_p^p + \frac{1}{q}\|Y\|_q^q \quad \text{if } 1/p + 1/q = 1$.
Minkowski' s inequality: $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p \quad \text{if } p \geq 1$.

2.3 切比雪夫不等式 Chebyshev' s Inequality

方差：$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$.
对单个随机变量：$\Pr[|X - \mathbb{E}[X]| \geq \epsilon] \leq \frac{\mathrm{Var}(X)}{\epsilon^2}$. 对 $f(X) = (X - \mathbb{E}[X])^2$ 使用马尔可夫不等式。
标准差：$\sigma(X) = \sqrt{\mathrm{Var}(X)}$.
对单个随机变量：$\Pr[|X - \mathbb{E}[X]| \geq \alpha \cdot \sigma(X)] \leq \frac{1}{\alpha^2}$.

对多随机变量均值：$\Pr[|X-\mu|\geq\epsilon]\leq\frac{\sigma^2}{n\epsilon^2}$，$\Pr[|X-\mu|\geq\alpha\cdot\frac{\sigma}{\sqrt{n}}]\leq\frac{1}{\alpha^2}$.

2.4 切尔诺夫界 Chernoff Bounds

矩生成函数 Moment generating function: $M_X(t):=\mathbb{E}[e^{tX}]$. 基本性质 $M(0)=1, M(t)\geq e^{t\mathbb{E}[X]}$.
Bernoulli: $\mathbb{E}[X]=p, \mathrm{Var}(X)=p(1-p), M_X(t)=(1-p)e^0+pe^t=1-p+pe^t$.
Binomial: $\mathbb{E}[X]=np, \mathrm{Var}(X)=np(1-p), M_X(t)=\prod_{i=1}^n\mathbb{E}[e^{tX_i}]=(1-p+pe^t)^n$.
Rademacher: $\mathbb{E}[X]=0, \mathrm{Var}(X)=1, M_X(t)=\frac{e^t+e^{-t}}{2}=\cosh t$.
Geometric: $\mathbb{E}[X]=\frac{1}{p}, \mathrm{Var}(X)=\frac{1-p}{p^2}, M_X(t)=\sum_k e^{tk}(1-p)^{k-1}p=\frac{pe^t}{1-(1-p)e^t}(t<-\log(1-p))$.
Generic Chernoff bound: $\Pr[X\geq a]\leq\inf_{t\in\mathbb{R}}\{e^{-ta}M(t)\}$ for $a\geq\mu$. 对 e^{tX} 使用 Markov.
率函数 Rate function: $I_X(a):=\sup_{t\in\mathbb{R}}\{ta-\log M_X(t)\}$.
Generic Chernoff bound: $\forall a\geq\mu, \Pr[X\geq a]\leq e^{-I(a)}; \forall a\leq\mu, \Pr[X\leq a]\leq e^{-I(a)}$.
$I(a)=+\infty$ if $a>u$ or $a<\ell$; $0\leq I(a)<+\infty$ for all $a\in[\ell,u]$; $I(\mu)=0$;
$I(a)$ is convex on the interval $[\ell,u]$.
对 i.i.d. 随机变量均值：$\forall a\geq\mu, \Pr[X\geq a]\leq e^{-nI(a)}; \forall a\leq\mu, \Pr[X\leq a]\leq e^{-nI(a)}$.
Cramér's theorem: 当 $n\to\infty$，对于固定的 $a\geq\mu$ 有 $\Pr[X^{(n)}\geq a]=e^{-n(I(a)+o(1))}$.

2.5 霍夫丁不等式 Hoeffding's Inequality

对于定义在 $[\ell,u]$ 上的随机变量 X, 有 $\mathbb{E}[e^{t(X-\mathbb{E}[X])}]\leq e^{t^2(u-\ell)^2/8}$ 且 $I_X(\mathbb{E}[X]+\epsilon)\geq 2\epsilon^2/(u-\ell)^2$.
对 i.i.d. 随机变量均值：$\Pr[|X-\mathbb{E}[X]|\geq\epsilon]\leq 2e^{-2n\epsilon^2/(u-\ell)^2}$.
对独立变量均值：$\Pr[|X-\mathbb{E}[X]|\geq\epsilon]\leq 2e^{-2n\epsilon^2/s^2}$，$s^2:=\frac{1}{n}\sum_{i=1}^n(u_i-\ell_i)^2$.
对独立变量总和：$\Pr[|X-\mathbb{E}[X]|\geq\epsilon]\leq 2e^{-2\epsilon^2/L^2}$，$L^2:=\sum_{i=1}^n(u_i-\ell_i)^2$.
鞅 Martingale：$(Z_i)_{i=0}^n$ 使得 $\mathbb{E}[Z_i\mid Z_{<i}]=Z_{i-1}$. 可拓展至定义在 $X_{\leq i}$ 上。
Azuma–Hoeffding: 对于鞅 $Z_{0\sim n}$，令 $\Delta_i=Z_i-Z_{i-1}\in[\widetilde{\ell}_i,\widetilde{u}_i]$, $\Pr[|Z_n-Z_0|\geq\epsilon]\leq 2e^{-2\epsilon^2/L^2}$.
Doob martingale: $Z_i:=\mathbb{E}[f(X_1,\ldots,X_n)\mid X_{\leq i}]$. 那么 $\mathbb{E}[Z_i\mid X_{<i}]=Z_{i-1}$.
McDiarmid's: 若 $f(x_1,\ldots,x_n)$ 对每一参数的变化值均有界 c_i，令 $L^2:=\sum_{i=1}^n c_i^2$，那么 $\Pr[|f(x_1,\ldots,x_n)-\mathbb{E}[f(x_1,\ldots,x_n)]|\geq\epsilon]\leq 2e^{-2\epsilon^2/L^2}, \mathrm{Var}\left[f\left(X_1,\ldots,X_n\right)\right]\leq\frac{1}{4}L^2$.

3 生成函数 Generating Functions

3.1 广义二项式定理 Newton's Generalized Binomial theorem

$(1+x)^r=\sum_k\binom{r}{k}x^k$，$\binom{r}{k}=\frac{r(r-1)\cdots(r-k+1)}{k!}$，$\binom{1/2}{n}=\frac{(-1)^{n-1}}{2^{2n-1}}\cdot\frac{(2n-2)!}{(n-1)!n!}$.

3.2 卡特兰数 Catalan Numbers

$C_n=\frac{1}{n+1}\binom{2n}{n}=\frac{(2n)!}{n!(n+1)!}=\binom{2n}{n}-\binom{2n}{n-1}$. $A(x)=xA^2(x)+1$, $A(x)=\frac{1-\sqrt{1-4x}}{2x}$.

3.3 封闭形式推导 Closed Form

对于 $A(x)=\frac{F(x)}{(1-\varphi x)(1-\psi x)}$ 的生成函数，分解为 $A(x)=F(x)\left(\frac{\alpha}{1-\varphi x}+\frac{\beta}{1-\psi x}\right)$.

3.4 简单微分方程 Differential Equation

整理为 $f'(x)+f(x)\cdot g(x)=h(x)$ 形式，令 $\mu(x)=\exp(\int g(x)\mathrm{d}x)$，则 $\mu(x)\cdot f(x)=\int\mu(x)\cdot h(x)\mathrm{d}x$.

3.5 复变函数 Complex Functions

复数 $z = x + iy = r(\cos\theta + i\sin\theta)$.

复幂级数：$f(z) = \sum_{k\geq 0} c_k(z-z_0)^k$. 收敛半径 $|z-z_0| < R = 1/\limsup_{k\to\infty} \sqrt[k]{|c_k|}$.

欧拉公式 $e^{ix} = \cos x + i\sin x$, $e^{i\pi} + 1 = 0$.

复数三角函数：$\sinh(ix) = i\sin x, \cosh(ix) = \cos x, \sinh(x) = -i\sin(ix), \cosh(x) = \cos(ix)$.

$|\sin z|^2 = \sin^2 x + \sinh^2 y, |\cos z|^2 = \cos^2 x + \sinh^2 y$.

3.6 全纯函数 Holomorphic Functions

连续：$\lim_{z\to z_0} f(z) = f(z_0)$. 可微：$f'(z_0) = \lim_{z\to z_0} \frac{f(z)-f(z_0)}{z-z_0}$. 注意 $f(z) = \overline{z}$ 处处不可微.

解析函数：若 f 在 z_0 的邻域内可展开为收敛的幂级数，则称 f 在 z_0 处解析。

对于复变函数，可微、无穷次可微、解析为等价条件。

全纯函数：称在 $z_0 \in S$ 处全纯当且仅当 f 在一个 z_0 的邻域内可微。

3.7 复积分 Complex Integrals

曲线：$\gamma : [a,b] \to \mathbb{C}$. 称曲线是简单闭曲线当且仅当其在 $[a,b)$ 上是单射，且 $\gamma(a) = \gamma(b)$.

围道：由连续可导的光滑曲线首尾相连形成围道。

线积分：$\int_\gamma f(z)\mathrm{d}z = \int_a^b f(\gamma(t))\gamma'(t)\mathrm{d}t$.

设 γ 为逆时针绕原点的简单闭合围道，则 $\int_\gamma z^n \mathrm{d}z = [n=-1]2\pi i$.

ML 不等式：如果 $|f(\gamma(t))| \leq M$ 对 $t \in [a,b]$ 成立，则 $\left|\int_\gamma f(z)\mathrm{d}z\right| \leq M \cdot L(\gamma)$.

柯西古萨定理：若 f 是定义在 S 上的全纯函数，γ 是 S 上的简单闭围道，且 γ 围住的区域也在 S 内，那么 $\int_\gamma f(z)\mathrm{d}z = 0$.

3.8 留数定理 Residue Theorem

奇点：若 f 在 z_0 处无定义或非全纯，且在 z_0 的邻域内存在点 z 全纯，则 z_0 为奇点。

孤立奇点：存在 z_0 的邻域全纯，则 z_0 为孤立奇点。

柯西积分公式：若 f 是定义在 S 上的全纯函数，γ 是 S 上逆时针方向的简单闭围道，且 γ 围住的区域也在 S 内，那么对于 γ 内部的点 z 有 $f(z) = \frac{1}{2\pi i}\int_\gamma \frac{f(w)}{w-z}\mathrm{d}w$.

直接推论：全纯函数泰勒级数展开 $f(z) = \sum_{n\geq 0} a_n(z-z_0)^n$，其中 $a_n = \frac{1}{2\pi i}\int_{C_r} \frac{f(w)}{(w-z_0)^{n+1}}\mathrm{d}w$.

证明：将 $f(z)$ 用柯西积分公式表示，则 $\frac{1}{w-z} = \frac{1}{w-z_0}\cdot\frac{1}{1-\frac{z-z_0}{w-z_0}}$.

恒等定理：若 $S \subseteq \mathbb{C}$ 是连通开集，$f, g : S \to \mathbb{C}$ 为 S 上的全纯函数，若存在非空开集 $U \subseteq S$ 使得 $\forall z \in U, f(z) = g(z)$，则对所有 $z \in S$ 均有 $f(z) = g(z)$.

泰勒级数的收敛半径恰好等于距离 z_0 最近的非可去奇点的距离。

洛朗级数：若 f 在去心圆盘 $D_r(z_0)\setminus\{z_0\}$ 内全纯，则对其中 z，有 $f(z) = \sum_{n=-\infty}^{+\infty} a_n(z-z_0)^n$.

可去奇点：$\forall n < 0, a_n = 0$；m 阶极点：$a_{-m} \neq 0, \forall n < -m, a_n = 0$. 本性奇点：存在无数多 $a_{-n} \neq 0$.

若 $\lim_{z\to z_0}(z-z_0)^m f(z)$ 存在且非 0，则 z_0 是 f 的 m 阶极点。

留数：$\mathrm{Res}(f, z_0)$ 为奇点 z_0 的洛朗展开的 a_{-1} 项。

柯西留数定理：记 f 在围道 γ 内的奇点为 $z_1, \ldots, z_m$，则 $\frac{1}{2\pi i}\int_\gamma f(z)\mathrm{d}z = \sum_{j=1}^m \mathrm{Res}(f, z_j)$.

若 z_0 是单极点，则 $\mathrm{Res}(f, z_0) = \lim_{z\to z_0}(z-z_0)f(z)$.

若 $f(z) = \frac{g(z)}{h(z)}$ 且 g, h 在 z_0 全纯，则 $\mathrm{Res}(f, z_0) = \frac{g(z_0)}{h'(z_0)}$.

若 z_0 是 m 阶极点，则 $\mathrm{Res}(f, z_0) = \frac{1}{(m-1)!}\lim_{z\to z_0}\frac{\mathrm{d}^{m-1}}{\mathrm{d}z^{m-1}}[(z-z_0)^m f(z)]$.

留数定理可帮助计算实轴上的反常积分：

1. 将实积分延拓为复平面上的围道积分（例如上半圆，或矩形），可能需添加虚部（$\cos x \to e^{iz}$）。

2. 找出被积函数在围道内的所有奇点并计算其留数，通过留数定理求围道积分。

3. 通过 ML 不等式证明辅助围道上的积分可忽略。

4. 可能需要通过周期性对无法忽略的辅助围道列方程。

留数定理帮助计算生成函数封闭形式：

1. 若 $f(z)$ 在 0 处全纯，则 $\frac{f^{(n)}(0)}{n!} = \operatorname{Res}\left(\frac{f(z)}{z^{n+1}}, 0\right)$. 定义 $g_n(z) = \frac{f(z)}{z^{n+1}}$，则我们有 $a_n = n! \cdot \operatorname{Res}(g_n, 0)$ (EGF) 或 $a_n = \operatorname{Res}(g_n, 0)$ (OGF).

2. 选择一个大围道 γ_R 包围 0，其中 R 是控制围道大小的参数，若当 $R \to \infty$ 时 $|g_n(z)| = o(R^{-1})$ 且 $L(\gamma_R) = \mathcal{O}(R)$，那么由 ML 不等式有 $\int_{\gamma_R} g_n(z)\mathrm{d}z \to 0$.

3. 根据留数定理，这意味着 $\lim_{R\to\infty} \sum_{z_0 \in S_R} \operatorname{Res}(g_n, z_0) = 0$.

4. 计算所有非 0 位置的留数，有 $\operatorname{Res}(g_n, 0) = -\lim_{R\to\infty} \sum_{z_0 \in S_R \setminus \{0\}} \operatorname{Res}(g_n, z_0)$.

3.9 拉格朗日反演定理 Lagrange Inversion Theorem

设 $f : S \to U, g : U \to S$ 为定义在开集上的全纯函数，且 f, g 互为反函数：$\forall z \in U, f(g(z)) = z$ 以及 $\forall w \in S, g(f(w)) = w$。假设 $0 \in S$ 且 $f(0) = 0$，则存在 r 使得 $\forall z \in D_r(0)$，有 $g(z) = \sum_{n\geq 1} g_n z^n = \sum_{n\geq 1} \operatorname{Res}(h_n, 0)\frac{z^n}{n}$，其中 $h_n(w) = \left(\frac{1}{f(w)}\right)^n$.

若 $F(z) = z\phi(F(z))$，则有 $[z^n]F(z) = \frac{1}{n}[z^{n-1}]\phi(z)^n$.

3.10 随机变量生成函数 Generating Functions of Random Variables

概率生成函数 PGF $G_X(z) = \mathbb{E}[z^X] = \sum_k \Pr[X = k]z^k$. 有 $G_X(1) = 1, \mathbb{E}[X] = G'_X(1), \operatorname{Var}(X) = G''_X(1) + G'_X(1) - G'_X(1)^2, G_{X+Y}(x) = G_X(x) \cdot G_Y(x)$.

矩生成函数 MGF $M_X(t) = \mathbb{E}[e^{tX}] = \sum_k \mathbb{E}[X^k]\frac{t^k}{k!}$.

累积量生成函数 CGF $K_X(t) = \log M_X(t) = \sum_m \kappa_m \frac{t^m}{m!}$. 其中 κ_m 为累积量，$\kappa_1 = \mathbb{E}[X], \kappa_2 = \operatorname{Var}(X), \kappa_3 = \mu(X) = \mathbb{E}[(X - \mathbb{E}[X])^3]$.

运算列表：平移 $X + c$：$e^{ct}M_X(t), ct + K_X(t)$；缩放 cX：$M_X(ct), K_X(ct)$；独立和 $X + Y$：$M_X(t)M_Y(t), K_X(t) + K_Y(t)$；期望 $\mathbb{E}[X]$：$M'_X(0), K'_X(0)$；二阶矩 $\mathbb{E}[X^2]$：$M''_X(0), K''_X(0) + K'_X(0)^2$；方差 $\operatorname{Var}(X)$：$M''_X(0) - M'_X(0)^2, K''_X(0)$。

引理：对于 $c > 0, \delta \in \mathbb{R}$，有 $\lim_{T\to+\infty} \frac{1}{2\pi i} \int_{\gamma_{c,T}(t)} \frac{e^{\delta z}}{z}\mathrm{d}z = 0/\frac{1}{2}/1$，判断 $\delta < 0/\delta = 0/\delta > 0$，其中 $\forall t \in [-T, T], \gamma_{c,T}(t) = c + it$.

定理：通过 MGF 可还原概率分布。定义 $p_X(x_1, x_2) = \frac{1}{2}\Pr[X = x_1] + \Pr[x_1 < X < x_2] + \frac{1}{2}\Pr[X = x_2]$，则 $p_X(x_1, x_2) = \frac{1}{2\pi i} \lim_{T\to+\infty} \int_{\gamma_{c,T}} \frac{e^{-x_1 z} - e^{-x_2 z}}{z} M_X(z)\mathrm{d}z$.

4 连续概率 Continuous Probability

4.1 概率分布 Probability Distribution

概率质量函数 PMF：对离散随机变量 X，定义 PMF $p_X(x) = \Pr[X = x]$.

概率密度函数 PDF：对连续随机变量 X，定义 PDF $f_X(x)$ 满足 $\Pr[a \leq X \leq b] = \int_a^b f_X(x)\mathrm{d}x$。

概率分布 PD：定义 PD 为集合向 $[0, 1]$ 的映射 $P_X(A) = \Pr[X \in A]$.

PMF 唯一确定离散随机变量分布，PDF 不唯一确定连续随机变量分布。

累计分布函数 CDF：对随机变量 X，定义 CDF $F_X(x) = \Pr[X \leq x]$.

4.2 高斯分布 Gaussian Distribution

标准高斯分布 $\mathcal{N}(0,1)$：$\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-x^2/2}$. 计算其积分 I 需计算 $I^2=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}e^{-(x^2+y^2)/2}\mathrm{d}x\mathrm{d}y=\int_0^{2\pi}\int_{-\infty}^{+\infty}e^{-r^2/2}\cdot r\mathrm{d}r\mathrm{d}\theta$.

PDF 的缩放与平移：$\alpha X+\beta$ 的 PDF 为 $\frac{1}{|\alpha|}f_X(\frac{x-\beta}{\alpha})$.

一般高斯分布 $\mathcal{N}(\mu,\sigma^2)$：PDF $f_X(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$；MGF $M_X(t)=e^{\mu t+\sigma^2t^2/2}, K_X(t)=\mu t+\sigma^2t^2/2$.

高斯变量之和：直接相加 μ 与 σ^2.

高斯尾界：定义 $\bar{\Phi}(x)=\int_x^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-u^2/2}\mathrm{d}u$ 为标准高斯分布的尾概率，当 $x\to+\infty$ 时有 $\bar{\Phi}(x)\sim\frac{1}{\sqrt{2\pi}}\frac{e^{-x^2/2}}{x}$. 对于高斯样本平均 $X=\frac{1}{n}\sum_{i=1}^n X_i$，其中 $X_i\sim\mathcal{N}(\mu,\sigma^2)$，在 $n\to\infty$ 时有 $\Pr[X\geq\mu+\epsilon]=\Pr[X\leq\mu-\epsilon]=\bar{\Phi}\left(\frac{\epsilon}{\sigma}\sqrt{n}\right)\sim\frac{\sigma}{\epsilon\sqrt{2\pi n}}e^{-n\epsilon^2/(2\sigma^2)}$.

高斯 Chernoff 界：$\Pr[X\geq\mu+\epsilon]=\Pr[X\leq\mu-\epsilon]\leq e^{-n\epsilon^2/(2\sigma^2)}$.

4.3 高斯向量 Gaussian Vector

随机向量 $\boldsymbol{x}$ 由概率分布 $P_{\boldsymbol{x}}(A)=\Pr[\boldsymbol{x}\in A]$ 决定，其协方差矩阵 $\mathrm{Cov}(\boldsymbol{x})=\mathbb{E}[(\boldsymbol{x}-\mathbb{E}[\boldsymbol{x}])(\boldsymbol{x}-\mathbb{E}[\boldsymbol{x}])^\top]$. 更直观地，$\mathrm{Cov}(\boldsymbol{x})_{i,j}=\mathrm{Cov}(X_i,X_j)$，其中 $\mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])]$。

若 X,Y 独立，则 $\mathrm{Cov}(X,Y)=0$.

标准高斯向量为 $\boldsymbol{x}=(X_1,\ldots,X_d)^\top$，其中 X_i 互相独立且 $X_i\sim\mathcal{N}(0,1)$。

随机向量 $\boldsymbol{x}\in\mathbb{R}^d$ 称为高斯随机向量当且仅当存在向量 $\boldsymbol{\mu}\in\mathbb{R}^d$ 和矩阵 $\boldsymbol{A}\in\mathbb{R}^{d\times r}$ 以及标准高斯向量 $\boldsymbol{z}\sim\mathcal{N}(\boldsymbol{0},\boldsymbol{I})$ 使得 $\boldsymbol{x}=\boldsymbol{\mu}+\boldsymbol{A}\boldsymbol{z}$. 记作 $\boldsymbol{x}\sim\mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$，其中 $\boldsymbol{\Sigma}=AA^\top$ 为协方差矩阵。

对向量参数 $\boldsymbol{t}\in\mathbb{R}^d$ 定义随机向量的 MGF 与 CGF：$M_{\boldsymbol{x}}(\boldsymbol{t})=\mathbb{E}\left[e^{\boldsymbol{t}^\top\boldsymbol{x}}\right], K_{\boldsymbol{x}}(\boldsymbol{t})=\log M_{\boldsymbol{x}}(\boldsymbol{t})$.

对于高斯随机向量 $\boldsymbol{x}\sim\mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$，有 $M_{\boldsymbol{x}}(\boldsymbol{t})=e^{\boldsymbol{t}^\top\boldsymbol{\mu}+\boldsymbol{t}^\top\boldsymbol{\Sigma}\boldsymbol{t}/2}, K_{\boldsymbol{x}}(\boldsymbol{t})=\boldsymbol{t}^\top\boldsymbol{\mu}+\frac{1}{2}\boldsymbol{t}^\top\boldsymbol{\Sigma}\boldsymbol{t}$.

高斯线性性：对于高斯随机向量 $\boldsymbol{x}\sim\mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$ 以及任意矩阵 $\boldsymbol{S}\in\mathbb{R}^{r\times d}$，有 $\boldsymbol{S}\boldsymbol{x}\sim\mathcal{N}(\boldsymbol{S}\boldsymbol{\mu},\boldsymbol{S}\boldsymbol{\Sigma}\boldsymbol{S}^\top)$.

高斯向量之和：直接相加 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Sigma}$.

4.4 高维几何 High Dimensions Geometry

高斯分布 $\mathcal{G}=\mathcal{N}(\boldsymbol{0},\boldsymbol{I}/d)$：我们有 $\mathbb{E}[\|x\|_2^2]=1$.

均匀球面分布 $\mathcal{U}_{\mathbb{S}}$：在单位球面 $\mathbb{S}^{d-1}=\{\boldsymbol{x}\in\mathbb{R}^d:\|x\|_2=1\}$ 上的均匀分布。

均匀球体分布 $\mathcal{U}_B$：在单位球 $B^d=\{\boldsymbol{x}\in\mathbb{R}^d:\|x\|_2\leq1\}$ 上的均匀分布。

定义 $\mu(A)=\int_A\mathrm{d}x$ 表示集合 A 的体积，有 $\frac{\mu((1-\epsilon)A)}{\mu(A)}=(1-\epsilon)^d\leq e^{-\epsilon d}$.

均匀球体分布集中在球面附近：设 $\boldsymbol{x}\sim\mathcal{U}_B$，那么 $\Pr[1-\epsilon<\|\boldsymbol{x}\|_2\leq1]\geq1-e^{-\epsilon d}$.

高斯分布集中在球面附近：设 $\boldsymbol{x}\sim\mathcal{G}$，那么对 $\epsilon\in(0,1)$ 有 $\Pr\left[\left|\|\boldsymbol{x}\|_2^2-1\right|\geq\epsilon\right]\leq2e^{-d\epsilon^2/8}$，对 $\epsilon>1$ 有 $\Pr\left[\|\boldsymbol{x}\|_2^2-1\geq\epsilon\right]\leq e^{-d\epsilon/8}$。对所有 $\epsilon>0$ 有 $\Pr\left[|\|\boldsymbol{x}\|_2-1|\geq\epsilon\right]\leq2e^{-d\epsilon^2/8}$。

分析方法：有 $\|x\|_2^2=\frac{1}{d}\sum_{i=1}^d Z_i^2$，其中 $Z_i\sim\mathcal{N}(0,1)$；分析 $M_{Z^2}(t)=\int_{\mathbb{R}}\frac{1}{\sqrt{2\pi}}e^{-(1-2t)x^2/2}\mathrm{d}x$，与 $\mathcal{N}(0,\frac{1}{1-2t})$ 比较可得 $M_{Z^2}(t)=\frac{1}{\sqrt{1-2t}}$ for $t<1/2$. 那么 $I_{Z^2}(a)=\sup_{t<1/2}\{ta+\frac{1}{2}\log(1-2t)\}=\frac{1}{2}(a-1-\log a)$. 对 $x\in(-1,1)$ 有 $x-\log(1+x)\geq\frac{x^2}{4}$，对 $x\geq1$ 有 $x-\log(1+x)\geq\frac{x}{4}$.

均匀球体分布集中在赤道平面附近：设 $\boldsymbol{x}\sim\mathcal{U}_B$，$d\geq3$，固定单位向量 $\boldsymbol{u}$，对任意 $\epsilon\in(0,1)$ 有 $\Pr[|\langle\boldsymbol{u},\boldsymbol{x}\rangle|<\epsilon]\geq1-6e^{-(d-1)\epsilon^2/2}$. 若 $\boldsymbol{x}\sim\mathcal{G}$，则上述界为 $\Pr[|\langle\boldsymbol{u},\boldsymbol{x}\rangle|<\epsilon]\geq1-2e^{-d\epsilon^2/2}$.

分析方法：对于 $\boldsymbol{x}\sim\mathcal{G}$，由高斯线性性有 $\langle\boldsymbol{u},\boldsymbol{x}\rangle\sim\mathcal{N}(0,1/d)$. 对于 $\boldsymbol{x}\sim\mathcal{U}_B$，考虑切片 $A_t:=\{\boldsymbol{x}\in B^d:\langle\boldsymbol{u},\boldsymbol{x}\rangle=t\}$,，为半径为 $\sqrt{1-t^2}$ 的 $(d-1)$ 维球，有 $\mu(A_t)=(1-t^2)^{(d-1)/2}\cdot V_{d-1}$. 据此计算 $\Pr[\langle\boldsymbol{u},\boldsymbol{x}\rangle\in(a,b)]$ 得到其 PDF $f(t)=\frac{1}{I}(1-t^2)^{(d-1)/2}$ for $t\in[-1,1]$，其中 $I=\int_{-1}^1(1-t^2)^{(d-1)/2}\mathrm{d}t$. 考虑 $\tilde{\varphi}(t)=\frac{\sqrt{d-1}}{\sqrt{2\pi}}e^{-(d-1)t^2/2}$ 为 $\mathcal{N}(0,\frac{1}{d-1})$ 的 PDF，则 $f(t)$ 被 $\frac{\sqrt{2\pi}}{I\sqrt{d-1}}\tilde{\varphi}(t)$

上界，有 $\Pr[\langle \boldsymbol{u},\boldsymbol{x}\rangle \geq \epsilon] \leq \frac{\sqrt{2\pi}}{I\sqrt{d-1}}\int_{\epsilon}^{+\infty}\tilde{\varphi}(t) \leq \frac{\sqrt{2\pi}}{I\sqrt{d-1}}e^{-(d-1)\epsilon^2/2}$。我们还可以通过限制积分区间、$(1-x)^{\alpha}\geq 1-\alpha x$ for $x\in[0,1],\alpha\geq 1$ 下界 $I\geq\frac{1}{\sqrt{d-1}}$.

均匀球体分布集中在赤道上：设 $\boldsymbol{x}\sim\mathcal{U}_B$，$d\geq 3$，固定单位向量 $\boldsymbol{u}$，对任意 $\epsilon\in(0,1)$ 有 $\Pr[|\langle \boldsymbol{u},\boldsymbol{x}\rangle|<\epsilon \text{ and } 1-\frac{1}{2}\epsilon^2<\|\boldsymbol{x}\|_2\leq 1]\geq 1-7e^{-(d-1)\epsilon^2/2}$.

随机方向几乎正交：设 $d\geq 3$，对任意 $\epsilon\in(0,1),\delta\in(0,1)$，存在 $N=\sqrt{\delta}e^{\Theta(d\epsilon^2)}$，使得对任意 $n\leq N$，如果从 $\mathcal{U}_{\mathbb{S}}$ 中独立采样 $\boldsymbol{x}_1,\ldots,\boldsymbol{x}_n$，则 $\Pr[\forall 1\leq i<j\leq n,|\langle \boldsymbol{x}_i,\boldsymbol{x}_j\rangle|<\epsilon]>1-\delta$.

分析方法：随机采样 $\boldsymbol{z}_i,\boldsymbol{z}_j\in\mathcal{U}_B$，令 $\boldsymbol{y}_i=\frac{\boldsymbol{z}_i}{\|\boldsymbol{z}_i\|_2},\boldsymbol{y}_j=\frac{\boldsymbol{z}_j}{\|\boldsymbol{z}_j\|_2}$，则 $(\boldsymbol{x}_i,\boldsymbol{x}_j)$ 与 $(\boldsymbol{y}_i,\boldsymbol{y}_j)$ 同分布。对任意 $\epsilon_0\in(0,1)$ 有 $1-7e^{-(d-1)\epsilon_0^2/2}$ 的概率 $|\langle \boldsymbol{z}_i,\boldsymbol{y}_j\rangle|<\epsilon_0$ 且 $1-\frac{1}{2}\epsilon_0^2<\|\boldsymbol{z}_i\|_2\leq 1$，此时 $|\langle \boldsymbol{y}_i,\boldsymbol{y}_j\rangle|\leq\frac{\epsilon_0}{1-\epsilon_0^2/2}<2\epsilon_0$. 取 $\epsilon=2\epsilon_0$，我们得到 $\Pr[|\langle \boldsymbol{y}_i,\boldsymbol{y}_j\rangle|\geq\epsilon]\leq 7e^{-(d-1)\epsilon^2/8}$. 令右侧为 δ/N^2，则有 $N=e^{(d-1)\epsilon^2/16+\log(\delta/7)/2}$.

4.5 随机投影 Random Projection

JL Lemma：给定一组 $\boldsymbol{x}_1,\ldots,\boldsymbol{x}_n\in\mathbb{R}^d$ 以及 $n\geq 2$，对任意 $\epsilon\in(0,1)$ 以及 $k\geq\frac{16\log n}{\epsilon^2}$，存在线性映射 $F:\mathbb{R}^d\to\mathbb{R}^k$ 使得对所有 (i,j)，$(1-\epsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2^2\leq\|F(\boldsymbol{x}_i)-F(\boldsymbol{x}_j)\|_2^2\leq(1+\epsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|_2^2$.

引理：令 $\boldsymbol{A}\in\mathbb{R}^{k\times d}$ 为高斯随机矩阵，其中元素均匀采样于 $\mathcal{N}(0,1/k)$，则 $\boldsymbol{A}\boldsymbol{x}\sim\mathcal{N}\left(\boldsymbol{0},\frac{\|\boldsymbol{x}\|_2^2}{k}\boldsymbol{I}\right)$，且 $\Pr\left[\left|\frac{\|\boldsymbol{A}\boldsymbol{x}\|_2^2}{\|\boldsymbol{x}\|_2^2}-1\right|\geq\epsilon\right]\leq 2e^{-k\epsilon^2/8}$.

故直接令 $F(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}$，以至少 $1-2e^{-k\epsilon^2/8}$ 的概率对一组 i,j 满足条件。通过 Union bound 得到对所有 i,j 满足条件的概率大于 0.

若允许 δ 的失败率，可允许 $k\geq\frac{8(2\log n-\log\delta)}{\epsilon^2}$.

4.6 概率距离 Probability Distance

总变差距离：$d_{\mathrm{TV}}(P,Q)=\sup_{A\subseteq\mathbb{R}^d}|P(A)-Q(A)|$.

离散公式：$d_{\mathrm{TV}}(P,Q)=\frac{1}{2}\sum_{x\in\mathcal{X}}|p(x)-q(x)|$.

连续公式：$d_{\mathrm{TV}}(P,Q)=\frac{1}{2}\int_{\mathbb{R}^d}|f(x)-g(x)|\mathrm{d}x$.

变分形式：对于 $\ell<u, d_{\mathrm{TV}}(P,Q)=\frac{1}{u-\ell}\sup_{\phi\in\mathcal{F}_{\ell,u}}|P(\phi)-Q(\phi)|$，其中 $\mathcal{F}_{\ell,u}$ 为所有 $\phi:\mathbb{R}^d\to[\ell,u]$ 构成的函数族，$P(\phi)=\mathbb{E}_P[\phi(X)]$.

5 中心极限定理 Central Limit Theorem

5.1 依分布收敛 Convergence in Distribution

依分布收敛 $X_n\xrightarrow{d}X$：对于所有连续集 A 均有 $X_n(A)\to X(A)$.

CDF 收敛准则：$D_n\xrightarrow{d}D$ 当且仅当对于所有 F_D 的连续点 x 均有 $F_{D_n}(x)\to F_D(x)$.

PMF 收敛准则：离散概率分布 $D_n\xrightarrow{d}D$ 当且仅当对于所有 $x\in\mathcal{X}$ 均有 $p_n(x)\to p(x)$.

PDF 收敛准则：若对于所有 $x\in\mathbb{R}^d$ 有 $f_n(x)\to f(x)$，则连续概率分布 $D_n\xrightarrow{d}D$.

MGF 收敛准则：若 M_{X_n} 和 M_X 均定义在某个公共开区间 $(-\epsilon,\epsilon)$ 上，且对每个 $t\in(-\epsilon,\epsilon)$ 均有 $M_{X_n}(t)\to M_X(t)$，那么 $X_n\xrightarrow{d}X$.

检验函数刻画：$D_n\xrightarrow{d}D$ 当且仅当对于每个有界连续函数 $\phi:\mathbb{R}^d\to\mathbb{R}$ 均有 $D_n(\phi)\to D(\phi)$.

5.2 大数定理 The Law of Large Numbers

弱大数定理：记 $X_1, \ldots, X_n$ 为 i.i.d. 随机变量，且 $\mathbb{E}[X_i] = \mu, \mathrm{Var}(X_i) = \sigma^2 < +\infty$，令 $X^{(n)} = \frac{1}{n}\sum_i X_i$，则对于任意 $\epsilon > 0$ 有 $\Pr\left[|X^{(n)} - \mu| \geq \epsilon\right] \to 0$；等价地，对于 $n \to \infty$，有 $X^{(n)} \xrightarrow{d} \mu$.

证明：切比雪夫不等式 + CDF 收敛准则。

5.3 中心极限定理 The Central Limit Theorem

中心极限定理：记 $X_1, \ldots, X_n$ 为 i.i.d. 随机变量，且 $\mathbb{E}[X_i] = \mu, \mathrm{Var}(X_i) = \sigma^2 < +\infty$，令 $X^{(n)} = \frac{1}{n}\sum_i X_i$，则 $\sqrt{n}\left(X^{(n)} - \mu\right) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.

MGF 存在时的证明：记 X_i 的 CGF 为 $K(t)$，令 $Z^{(n)} = \sqrt{n}\left(X^{(n)} - \mu\right)$，那么 $K_{Z^{(n)}}(t) = nK\left(\frac{t}{\sqrt{n}}\right) - \sqrt{n}\mu t = n\left(\mu \cdot \frac{t}{\sqrt{n}} + \frac{\sigma^2}{2} \cdot \frac{t^2}{n} + \mathcal{O}(n^{-3/2})\right) - \sqrt{n}\mu t \to \frac{\sigma^2 t^2}{2}$.

多维版本：记 $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$ 为 i.i.d. 随机向量，且 $\mathbb{E}[\boldsymbol{x}_i] = \boldsymbol{\mu}, \mathrm{Cov}(\boldsymbol{x}_i) = \Sigma$，令 $\boldsymbol{x}^{(n)} = \frac{1}{n}\sum_i \boldsymbol{x}_i$，则 $\sqrt{n}\left(\boldsymbol{x}^{(n)} - \boldsymbol{\mu}\right) \xrightarrow{d} \mathcal{N}(\boldsymbol{0}, \boldsymbol{\Sigma})$.

5.4 置信区间 Confidence Interval

记 (a, b) 为参数 θ 的置信水平为 $1 - \delta$ 的置信区间，若 $\Pr[\theta \in (a, b)] \geq 1 - \delta$.

记 $X_1, \ldots, X_n$ 为 i.i.d. 随机变量，且 $\mathbb{E}[X_i] = \mu, \mathrm{Var}(X_i) = \sigma^2 < +\infty$，令 $X^{(n)} = \frac{1}{n}\sum_i X_i$，那么对于任意 $\alpha > 0$，当 $n \to \infty$ 时，有 $\Pr\left[\left|X^{(n)} - \mu\right| \leq \alpha \cdot \frac{\sigma}{\sqrt{n}}\right] \geq 1 - 2\bar{\Phi}(\alpha)$. 令 $\alpha(\delta)$ 为 $2\bar{\Phi}(\alpha(\delta)) = \delta$ 的解，那么区间 $\left(X^{(n)} - \alpha(\delta) \cdot \frac{\sigma}{\sqrt{n}}, X^{(n)} + \alpha(\delta) \cdot \frac{\sigma}{\sqrt{n}}\right)$ 为 μ 的置信水平为 $1 - \delta + o(1)$ 的置信区间。

6 优化 Optimization

6.1 对称矩阵 Symmetric Matrix

矩阵 $\boldsymbol{A} \in \mathbb{R}^{d \times d}$ 对称当且仅当 $\boldsymbol{A} = \boldsymbol{A}^\top$，可被正交对角化为 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$，其中 $\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \ldots, \lambda_d)$，$\boldsymbol{Q}$ 的列为 $\boldsymbol{A}$ 的特征向量.

特征向量：对于矩阵 $\boldsymbol{A}$ 存在一些向量 $\boldsymbol{v}$ 满足 $\boldsymbol{A}\boldsymbol{v} = \lambda\boldsymbol{v}$，则 λ 为 $\boldsymbol{A}$ 的特征值，$\boldsymbol{v}$ 为 λ 对应的特征向量。实对称矩阵的特征向量两两正交。

矩阵 $\boldsymbol{A} \in \mathbb{R}^{d \times d}$ 正定 $\boldsymbol{A} \succ 0$ 当且仅当对所有 $\boldsymbol{v} \in \mathbb{R}^d \setminus \{\boldsymbol{0}\}$ 有 $\boldsymbol{v}^\top \boldsymbol{A}\boldsymbol{v} > 0$，半正定 $\boldsymbol{A} \succeq 0$ 当且仅当对所有 $\boldsymbol{v} \in \mathbb{R}^d$ 有 $\boldsymbol{v}^\top \boldsymbol{A}\boldsymbol{v} \geq 0$.

$A \succeq 0$ 当且仅当所有特征值非负，$A \succ 0$ 当且仅当所有特征值为正。

对称半正定矩阵的条件数 $\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$.

矩阵的算子范数：$\|\boldsymbol{A}\|_2 = \max_{\boldsymbol{x} \in \mathbb{R}^d \setminus \{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2} = \sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})}$.

对对称矩阵有 $\|\boldsymbol{A}\|_2 = \max\{|\lambda_{\max}(\boldsymbol{A})|, |\lambda_{\min}(\boldsymbol{A})|\}$，对对称半正定矩阵有 $\|\boldsymbol{A}\|_2 = \lambda_{\max}(\boldsymbol{A})$.

6.2 线性回归 Linear Regression

给定数据 $(\boldsymbol{x}_i, y_i), \boldsymbol{x}_i \in \mathbb{R}^d, y_i \in \mathbb{R}$ 与线性模型 $f_{\boldsymbol{\theta}}(\boldsymbol{x}) = \langle \boldsymbol{x}, \boldsymbol{\theta} \rangle$，用均方误差 MSE 衡量数据 $\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2n}\sum_{i=1}^n (\langle \boldsymbol{x}_i, \boldsymbol{\theta} \rangle - y_i)^2 = \frac{1}{2n}\|\boldsymbol{X}\boldsymbol{\theta} - \boldsymbol{y}\|_2^2$，其中 $\boldsymbol{X} \in \mathbb{R}^{n \times d}$ 为第 i 行为 $\boldsymbol{x}_i^\top$ 的矩阵，$\boldsymbol{y} = (y_1, \ldots, y_n)^\top$.

展开范数得到 $\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2}\boldsymbol{\theta}^\top \boldsymbol{H}\boldsymbol{\theta} - \boldsymbol{b}^\top \boldsymbol{\theta} + \boldsymbol{C}_0$，其中 $\boldsymbol{H} = \frac{1}{n}\boldsymbol{X}^\top \boldsymbol{X}, \boldsymbol{b} = \frac{1}{n}\boldsymbol{X}^\top \boldsymbol{y}, \boldsymbol{C}_0 = \frac{1}{2n}\|\boldsymbol{y}\|_2^2$.

6.3 梯度下降 Gradient Descent

函数 $\mathcal{L}:\mathbb{R}^d\to\mathbb{R}$ 在点 $\boldsymbol{\theta}\in\mathbb{R}^d$ 处的梯度 $\nabla\mathcal{L}(\boldsymbol{\theta})$ 为一个 $\mathbb{R}^d$ 中的向量，其中第 i 个坐标为 $\mathcal{L}$ 对 $\boldsymbol{\theta}$ 的第 i 个坐标的偏导 $\frac{\partial\mathcal{L}}{\partial\theta_i}$.

$\boldsymbol{\theta}^*$ 为 $\mathcal{L}$ 的极小值点的一个必要条件为 $\nabla\mathcal{L}(\boldsymbol{\theta}^*)=\mathbf{0}$.

梯度下降：给定一个可微损失函数 $\mathcal{L}:\mathbb{R}^d\to\mathbb{R}$，初始参数向量 $\boldsymbol{\theta}_0\in\mathbb{R}^d$ 和学习率 $\eta>0$，梯度下降根据以下规则迭代更新参数向量：$\boldsymbol{\theta}_{t+1}=\boldsymbol{\theta}_t-\eta\nabla\mathcal{L}(\boldsymbol{\theta}_t)$.

对二次目标函数 $\mathcal{L}(\boldsymbol{\theta})=\frac{1}{2}\boldsymbol{\theta}^\top\boldsymbol{H}\boldsymbol{\theta}-\boldsymbol{b}^\top\boldsymbol{\theta}+\boldsymbol{C}_0$ 的优化，其中 $H\in\mathbb{R}^{d\times d}$ 为对称半正定矩阵。若 H 非半正定，则目标函数可任意减小。

上述目标函数的梯度为 $\nabla\mathcal{L}(\boldsymbol{\theta})=\boldsymbol{H}\boldsymbol{\theta}-\boldsymbol{b}$，因此 $\boldsymbol{\theta}^*=\boldsymbol{H}^{-1}\boldsymbol{b}$。在极小值点 $\boldsymbol{\theta}^*$ 附近，我们可以将二次目标函数重写为 $\mathcal{L}(\boldsymbol{\theta})=\frac{1}{2}(\boldsymbol{\theta}-\boldsymbol{\theta}^*)^\top\boldsymbol{H}(\boldsymbol{\theta}-\boldsymbol{\theta}^*)+\mathcal{L}_{\min}$，其中 $\mathcal{L}_{\min}=\boldsymbol{C}_0-\frac{1}{2}\boldsymbol{\theta}^{*\top}\boldsymbol{H}\boldsymbol{\theta}^*$.

对 $\boldsymbol{\theta}$ 求导得到 $\nabla\mathcal{L}(\boldsymbol{\theta})=\boldsymbol{H}(\boldsymbol{\theta}-\boldsymbol{\theta}^*)$，因此 $\boldsymbol{\theta}_{t+1}-\boldsymbol{\theta}^*=(\boldsymbol{I}-\eta\boldsymbol{H})(\boldsymbol{\theta}_t-\boldsymbol{\theta}^*)$.

在 $\boldsymbol{H}$ 的标准正交特征基 $\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_d\}$ 中重写上式，令 $\boldsymbol{\theta}_t-\boldsymbol{\theta}^*=\sum_{i=1}^d\alpha_{t,i}\boldsymbol{v}_i$，我们有 $\boldsymbol{\theta}_t-\boldsymbol{\theta}^*=\sum_{i=1}^d\alpha_{0,i}(1-\eta\lambda_i)^t\boldsymbol{v}_i$，$\mathcal{L}(\boldsymbol{\theta}_t)-\mathcal{L}_{\min}=\frac{1}{2}\sum_{i=1}^d\lambda_i\alpha_{0,i}^2(1-\eta\lambda_i)^{2t}$.

为使坐标收敛，我们需要 $|1-\eta\lambda_i|<1$，即 $0<\eta<\frac{2}{\lambda_{\max}}$.

收敛率：定义 $\rho(\eta)=\max_{i=1}^d|1-\eta\lambda_i|$，则 $\mathcal{L}(\boldsymbol{\theta}_t)-\mathcal{L}_{\min}=\Theta\left(\rho(\eta)^{2t}\right)$. 我们有 $\eta^*=\frac{2}{\lambda_{\min}+\lambda_{\max}}$，$\rho(\eta^*)=1-\frac{2}{1+\lambda_{\max}/\lambda_{\min}}=1-\frac{2}{1+\kappa}$，带回收敛率得到 $\mathcal{L}(\boldsymbol{\theta}_t)-\mathcal{L}_{\min}=\Theta\left(\left(1-\frac{2}{1+\kappa}\right)^{2t}\right)=e^{-\Theta(t/\kappa)}$.